

Suplemento S1 — Validación en simulación del diseño de prueba

Material suplementario

Camilo Alejandro Sjöberg Tala · Investigador independiente

Este suplemento amplía §6.7 del texto principal. Su alcance es acotado y conviene declararlo de entrada: valida las propiedades estadísticas del análisis discriminante descrito en §6.6, sobre datos sintéticos. No es evidencia a favor de AFH, ni sustituye la prueba de las Predicciones 6 y 7 sobre registros neurales reales.

S1.1 Métodos de simulación

Cada ensayo simulado genera cuatro variables: un impulsor de arousal latente z , un impulsor de estímulo s , la activación temprana ascendente E y el retorno tardío R . Ambos impulsores afectan a E y a R , y el análisis dispone únicamente de proxies ruidosos de z y de s , no de sus valores verdaderos —salvo en la condición de oráculo, que los usa para aislar el efecto del proxy imperfecto—. Bajo **Tipo A**, R se genera a partir de z y s más ruido independiente, sin ningún término que dependa de la fluctuación idiosincrática de E : por construcción, $P(R | E, z, s) = P(R | z, s)$. Bajo **Tipo B**, R incorpora además un término de eco proporcional a la parte de E no explicada por z y s , con una ganancia de acoplamiento que fija el tamaño de efecto. En ambos casos se añade ruido gaussiano independiente a E , a R y a los proxies.

El test de dependencia por ensayo (§6.6) se evaluó con N entre 50 y 300 ensayos. El test de identificabilidad se evaluó sobre 80 repeticiones independientes en cada uno de cuatro tamaños ($N = 400, 800, 1600, 2400$), ajustando un mapeo temprano→tardío y midiendo la tasa de identificación correcta del ensayo verdadero (top-1) frente a una distribución nula construida por permutación de la correspondencia entre ensayos, emparejando por arousal y estímulo. El criterio estadístico es la comparación de la tasa top-1 observada contra esa nula por permutación; la tasa de falsos positivos se estima como la proporción de repeticiones bajo Tipo A que superan el umbral nominal $\alpha = 0,05$. Los tests confirmatorios se declararon por adelantado y se distinguen de los descriptivos, de modo que no se aplica corrección post-hoc por comparaciones múltiples sobre ellos.

Los valores concretos de los parámetros (varianzas de ruido, ganancias de acoplamiento, fidelidad de los proxies) y las semillas aleatorias están fijados en el código de simulación, disponible en el repositorio público indicado en las Declaraciones; los resultados de este apartado se reproducen ejecutándolo sin modificación.

S1.2 La vulnerabilidad de estímulo compartido

El test de rastreo de identidad se sometió a revisión adversarial, que localizó una vulnerabilidad real: sin estructura de estímulo compartido, el test podía estar identificando el estímulo y no el linaje causal —un falso Tipo B bajo Tipo A puro—. Construido el escenario exacto de la crítica, el fallo se confirmó, y la corrección —condicionar por estímulo además de arousal— lo redujo a un residuo marginal, que solo con el confusor verdadero desaparece del todo.

Modelo / versión	top-1 observada	top-1 nula	p
Tipo A — ingenua (solo arousal)	0,087	0,017	$p < 0,0001$ (falso positivo confirmado)
Tipo A — condicionada (arousal + estímulo)	0,030	0,017	$p = 0,037$ (residuo marginal)
Tipo A — condicionada (oráculo, confusor verdadero)	0,010	0,017	$p = 0,98$ (limpio)

Tabla S1. Identificabilidad bajo Tipo A puro con estímulo como causa común. El chequeo contra el oráculo separa mecanismo de proxy: con el confusor verdadero, el residuo desaparece.

La lectura importa para el uso en datos reales. Con proxies imperfectos, que son los que habrá en cualquier registro, el test corregido no queda perfectamente limpio, sino acotado.

S1.3 Sensibilidad y estabilidad de la tasa de falsos positivos

Un chequeo con una sola semilla prueba especificidad, no sensibilidad ni estabilidad. Condicionar por estímulo colapsa la señal a su fluctuación idiosincrática, de menor relación señal-ruido, de modo que había que confirmar dos cosas: que el test corregido sigue detectando Tipo B real, y que su tasa de falsos positivos no crece con N como la de la prueba de magnitud. Sobre 80 repeticiones en cada uno de cuatro tamaños muestrales:

N	FPR, error 1 %	FPR, error 8 %	FPR oráculo	Poder (Tipo B)
400	0,037	0,200	0,037	1,000
800	0,037	0,400	0,025	1,000
1600	0,062	0,787	0,025	1,000
2400	0,062	0,887	0,062	1,000

Tabla S2. Tasa de falsos positivos y poder del test corregido, por tamaño muestral, bajo dos regímenes de fidelidad del etiquetado de estímulo.

La estabilidad de la tasa de falsos positivos resultó condicional a la fidelidad del proxy de identidad de estímulo, y no incondicional. Con una tasa de error de clasificación de ~1 % (plausible si la identidad de estímulo la registra el propio software de la tarea), la FPR se mantiene plana y cerca de $\alpha = 0,05$. Con ~8 % (no exótico si la identidad se infiere post-hoc o hay codificación manual), la FPR se dispara con N —de 0,20 a 0,89 entre N = 400 y N = 2400—, superando el problema de la prueba de magnitud que motivó la corrección en primer lugar. El poder de detección de Tipo B se mantiene en 1,000 en ambos regímenes: la corrección no sacrificó sensibilidad, pero su robustez frente a falsos positivos sí depende de la calidad del etiquetado.

S1.4 Límites

Tres límites honestos. El poder saturado en 1,000 no traza dónde empieza a caer, y localizar el tamaño de efecto mínimo detectable exigiría repetir con un acoplamiento más débil, algo aún no hecho. Estos valores reflejan el régimen de parámetros simulado; no deben extrapolarse a señales intracraneales reales, cuya relación señal-ruido, no estacionariedad y estructura de confusores serán menos favorables. Y la estabilidad de la FPR del test corregido depende de la fidelidad del etiquetado de estímulo del registro real, que debe auditarse antes de confiar en el resultado: no es una propiedad garantizada de la corrección en sí.

Techo epistémico. Incluso corregidos y validados, todos estos tests son inferencia observacional bajo el supuesto de que no hay una causa común no medida. El chequeo contra el oráculo muestra que ese supuesto es el que carga el peso: solo con el confusor verdadero el residuo desaparece por completo. Únicamente una manipulación interventiva rompería ese techo, y probablemente excede lo disponible en una cohorte clínica. Un resultado positivo en datos reales sería, por tanto, corroborativo bajo supuestos declarados, no una prueba causal concluyente.

S1.5 Disponibilidad de código

Los valores concretos de los parámetros (varianzas de ruido, ganancias de acoplamiento, fidelidad de los proxies) y las semillas aleatorias están fijados en el código de simulación, disponible en el repositorio público indicado en las Declaraciones del artículo. Los resultados de las Tablas S1 y S2 se reproducen ejecutándolo sin modificación.